

Платформа документации провайдеров Terraform

Автоматизированный сбор, обработка и векторизация документации провайдеров Terraform для управления инфраструктурой на основе ИИ



Цель проекта

Создание аналитической платформы для автоматизированного сбора, очистки, предварительной обработки, маркировки и хранения документации Terraform provider для обеспечения AI агента актуальными, структурированными данными для генерации корректных Terraform configurations.

Платформа решает критические проблемы в DevOps automation, где AI агенты, управляющие инфраструктурой, требуют надежной, версионированной документации для множества Terraform providers.

Основные возможности

- Автоматизированный web scraping of provider docs
- Конвертация HTML to structured text
- Организация данных с учетом Version-aware
- Генерация Vector embedding
- Quality assurance pipelines

Проблема бизнеса

Область: DevOps / Infrastructure as Code (Terraform)

Фрагментированные источники

Документация, разбросанная по многочисленным реестрам, официальным сайтам и репозиториям провайдеров, затрудняет унифицированный доступ для автоматизированных систем.

Сложность HTML

Исходный формат HTML с навигационными элементами, меню и несущественным контентом требует сложного синтаксического анализа для извлечения значимой документации.

Несоответствия версий

Различия между версиями провайдеров создают риск генерации неверных конфигураций, когда контекст версии теряется или не соответствует.

Без структурированной, чувствительной к версиям документации, AI agents рисуют создавать некорректные конфигурации Terraform, что может привести к сбоям инфраструктуры и уязвимостям безопасности.

Стратегия сбора данных

01

Идентификация источников

Официальные сайты документации провайдеров Terraform, реестры провайдеров с информацией о версиях, страницы ресурсов, источники данных и руководства по использованию.

02

Обнаружение провайдеров

Автоматический поиск и компиляция списков провайдеров с их доступными версиями из Terraform Registry API.

03

Web Scraping

Извлечение страниц документации для каждой пары "провайдер-версия", захватывающее полный HTML с метаданными.

04

Сохранение метаданных

Хранение необработанных HTML-документов с URL, версией провайдера и аннотациями типа страницы для отслеживаемости.



Конвейер очистки и предварительной обработки

Очистка данных

- Удаление навигационных и вспомогательных элементов
- Извлечение основного содержимого страницы
- Сохранение структуры заголовков и таблиц
- Сохранение вложенных блоков и примеров кода *HCL*
- Преобразование *HTML* в чистый текстовый формат

Нормализация

- Стандартизация форматирования текста
- Унификация названий и структуры разделов
- Восстановление отсутствующих заголовков разделов
- Проверка целостности описаний аргументов

Разметка данных

Извлечение логических разделов и обогащение метаданных:

- Arguments

Входные параметры и опции конфигурации

- Attributes

Выходные значения и вычисляемые свойства

- Import

Инструкции по импорту ресурсов

- Examples

Примеры кода *HCL* и шаблоны использования

Архитектура хранения



Файловое хранилище

Необработанные HTML и очищенные TXT файлы, организованные по провайдеру и версии

MongoDB

Хранение метаданных с настройками провайдера и отслеживанием версий

Qdrant

Векторная база данных для индексированных текстовых фрагментов и семантического поиска

Многоуровневый подход к хранению данных поддерживает взаимосвязи между необработанными документами, обработанным контентом и векторными встраиваниями, обеспечивая эффективный поиск для запросов AI-агентов.

Архитектура платформы




Точка входа

`src/documentation_processing/main.py` создает контейнер зависимостей и запускает `Application.run()`

Выполнение воркера


`DocumentationProcessingWorker` выполняет конвейер, затем спит 24 часа перед следующим циклом

Контекст системы (C4 диаграмма)




На этой диаграмме представлен общий обзор "Платформы документации провайдеров Terraform", ее основных пользователей и внешних систем, с которыми она взаимодействует.

Диаграмма контейнеров



На этой диаграмме представлено высокоуровневое взаимодействие между ключевыми компонентами платформы, включая внутренние службы и внешние системы, обеспечивающие полный цикл обработки документации.

Диаграмма компонентов



Эта диаграмма детализирует внутренние компоненты платформы и их взаимодействия, демонстрируя, как обрабатывается документация от сбора до векторизации и загрузки.

Этапы конвейера обработки



Конфигурация и зависимости

Переменные окружения (DPB_*)

<i>MongoDB</i>	<i>DPB_DB_MONGO_*</i> для настроек и истории версий
<i>Qdrant</i>	<i>DPB_DB_QDRANT_*</i> для подключения к векторному хранилищу
<i>OpenAI</i>	Ключ API, название модели, необязательный базовый URL
<i>Общие</i>	Имя коллекции, настройки уровня логирования

Основные зависимости

- Beanie/MongoDB

Настройки провайдера и отслеживание обработанных версий

- aiohttp

Асинхронный HTTP-клиент для вызовов Registry API

- kdctl CLI

Подготовка документов, векторизация и загрузка